

隐马尔可夫模型 HMM

贺成

2020/1/14

背景



安德烈·马尔可夫(Андрей Андреевич Марков)

俄国数学家, 1856.6-1922.7

主要成就: 随机过程 (马尔可夫链, 马尔可夫过程)

师从



切比雪夫

马尔可夫链

假设有一句话 $S = (w_1, w_2, w_3, \dots, w_n)$ 由 n 个单词构成, 求这句话出现的概率 $P(S)$.

$$P(S) = P(w_1, w_2, w_3, \dots, w_n) = P(w_1) \cdot P(w_2|w_1) \cdot P(w_3|w_1, w_2) \cdots P(w_n|w_1, w_2, \dots, w_{n-1})$$

根本没法算!


假设1: 每个单词都是独立的, $P(S) = P(w_1, w_2, w_3, \dots, w_n) = P(w_1) \cdot P(w_2) \cdot P(w_3) \cdots P(w_n)$

假设2: 每个单词只与前一个单词有关, $P(S) = P(w_1, w_2, w_3, \dots, w_n) = P(w_1) \cdot P(w_2|w_1) \cdot P(w_3|w_2) \cdots P(w_n|w_{n-1})$

假设1 —> 朴素贝叶斯

假设2 —> 马尔可夫假设

我们把符合马尔可夫假设的随机过程称为**马尔可夫链** (马尔可夫过程)



隐马尔可夫模型

马尔可夫模型是马尔可夫链的一个扩展，在任意时刻 t 状态 s_t 是不可见的，隐藏的。但在每个时刻 t 会输出一个值 o_t ， o_t 由 s_t 决定，且只由 s_t 决定。隐藏的状态 s_1, s_2, \dots, s_t 是一个马尔可夫链。

独立输出假设


马尔可夫假设

马尔可夫模型是一个生成式模型，因此对联合概率建模：

$$P(O, S) = \prod_T P(o_t | s_t) \cdot P(s_t | s_{t-1})$$

$$P(o_1, o_2, o_3, \dots | s_1, s_2, s_3, \dots) = \prod_t P(o_t | s_t) \text{ (独立输出假设)}$$

$$P(s_1, s_2, s_3, \dots) = \prod_t P(s_t | s_{t-1}) \text{ (马尔可夫假设)}$$



隐马尔可夫模型应用



Baker夫妇

语音识别
→
20世纪70年代

错误率从30%降到10%



李开复

语音识别
→
20世纪80年代

世界上第一个大词汇量连续
语音识别系统Sphinx




Gary A. Churchill

生物序列
→
1989年

从那之后，在生物信息学领域HMM逐渐
成为一项不可或缺的技术

However,..... 隐马尔可夫模型并不是马尔可夫发明的



Leonard E. Baum

而是鲍姆等人在20世纪六七十年代提出的，HMM训练方法中的**鲍姆-韦尔奇算法**即是以他的名字命名的。

隐马尔可夫模型


- 组成

- 初始概率分布
- 状态转移概率分布
- 观测概率分布
- Q: 所有可能状态的集合
- V: 所有可能观测的集合

$$Q = \{q_1, q_2, \dots, q_N\}, \quad V = \{v_1, v_2, \dots, v_M\}$$

- I: 长度为T的状态序列
- O: 对应的观测序列

$$I = (i_1, i_2, \dots, i_T), \quad O = (o_1, o_2, \dots, o_T)$$



隐马尔可夫模型


状态转移矩阵A:

$$A = [a_{ij}]_{N \times N}$$

其中,

$$a_{ij} = P(i_{t+1} = q_j | i_t = q_i), \quad i = 1, 2, \dots, N; \quad j = 1, 2, \dots, N$$

是在时刻 t 处于状态 q_i 的条件下在时刻 $t+1$ 转移到状态 q_j 的概率。



隐马尔可夫模型

B 是观测概率矩阵:

$$B = [b_j(k)]_{N \times M}$$

其中,

$$b_j(k) = P(o_t = v_k | i_t = q_j), \quad k = 1, 2, \dots, M; \quad j = 1, 2, \dots, N$$

是在时刻 t 处于状态 q_j 的条件下生成观测 v_k 的概率。


π 是初始状态概率向量:

$$\pi = (\pi_i)$$

其中,

$$\pi_i = P(i_1 = q_i), \quad i = 1, 2, \dots, N$$

是时刻 $t = 1$ 处于状态 q_i 的概率。



隐马尔可夫模型

隐马尔可夫模型由初始状态概率向量 π 、状态转移概率矩阵 A 和观测概率矩阵 B 决定。 π 和 A 决定状态序列， B 决定观测序列。因此，隐马尔可夫模型 λ 可以用三元符号表示，即

$$\lambda = (A, B, \pi) \quad (10.7)$$

A, B, π 称为隐马尔可夫模型的三要素。

两个基本假设：

- **隐藏状态符合马尔可夫假设**，即任意时刻的状态只依赖于前一状态，和其他状态以及观测状态都无关
- **观测独立性假设**，即任意时刻观测只依赖于该时刻的隐状态，与其他观测状态无关。

例子


例 10.1（盒子和球模型） 假设有 4 个盒子，每个盒子里都装有红、白两种颜色的球，盒子里的红、白球数由表 10.1 列出。

		表 10.1 各盒子的红、白球数			
		盒 子			
		1	2	3	4
红球数		5	3	6	8
白球数		5	7	4	2

按照下面的方法抽球，产生一个球的颜色的观测序列：

- 开始，从 4 个盒子里以等概率随机选取 1 个盒子，从这个盒子里随机抽出 1 个球，记录其颜色后，放回；
- 然后，从当前盒子随机转移到下一个盒子，规则是：如果当前盒子是盒子 1，那么下一盒子一定是盒子 2；如果当前是盒子 2 或 3，那么分别以概率 0.4 和 0.6 转移到左边或右边的盒子；如果当前是盒子 4，那么各以 0.5 的概率停留在盒子 4 或转移到盒子 3；
- 确定转移的盒子后，再从这个盒子里随机抽出 1 个球，记录其颜色，放回；
- 如此下去，重复进行 5 次，得到一个球的颜色的观测序列：

$O = (\text{红}, \text{红}, \text{白}, \text{白}, \text{红})$



Task: 根据前面隐马尔可夫模型的定义写出状态集合 Q ，观测集合 V ，初始概率分布 π ，状态转移概率分布 A ，观测概率分布 B 。

盒子对应状态，状态的集合是：

$$Q = \{\text{盒子 1}, \text{盒子 2}, \text{盒子 3}, \text{盒子 4}\}, \quad N = 4$$

球的颜色对应观测。观测的集合是：

$$V = \{\text{红}, \text{白}\}, \quad M = 2$$

状态转移概率分布为

$$A = \begin{matrix} & \begin{matrix} \text{盒1} & \text{盒2} & \text{盒3} & \text{盒4} \end{matrix} \\ \begin{matrix} \text{盒1} \\ \text{盒2} \\ \text{盒3} \end{matrix} & \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0.4 & 0 & 0.6 & 0 \\ 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0.5 & 0.5 \end{bmatrix} \end{matrix}$$

观测概率分布为

$$B = \begin{matrix} & \begin{matrix} \text{红球} & \text{白球} \end{matrix} \\ \begin{matrix} \text{盒1} \\ \text{盒2} \\ \text{盒3} \\ \text{盒4} \end{matrix} & \begin{bmatrix} 0.5 & 0.5 \\ 0.3 & 0.7 \\ 0.6 & 0.4 \\ 0.8 & 0.2 \end{bmatrix} \end{matrix}$$

HMM观测序列的生成过程

算法 10.1 (观测序列的生成)

输入：隐马尔可夫模型 $\lambda = (A, B, \pi)$ ，观测序列长度 T ；

输出：观测序列 $O = (o_1, o_2, \dots, o_T)$ 。


(1) 按照初始状态分布 π 产生状态 i_1 ；

(2) 令 $t = 1$ ；

(3) 按照状态 i_t 的观测概率分布 $b_{i_t}(k)$ 生成 o_t ；

(4) 按照状态 i_t 的状态转移概率分布 $\{a_{i_t i_{t+1}}\}$ 产生状态 i_{t+1} ， $i_{t+1} = 1, 2, \dots, N$ ；

(5) 令 $t = t + 1$ ；如果 $t < T$ ，转步 (3)；否则，终止。 ■



隐马尔可夫模型的三个基本问题

1、概率计算问题：

给定一个模型如何计算某个特定的输出序列的概率，即计算 $P(O|\lambda)$

2、学习问题：

给足够量的观测数据，如何估计出HMM模型的参数 $\lambda = (A, B, \pi)$

3、预测问题（解码）：

给定一个模型和某个特定的输出序列，如何找到最可能产生这个输出的隐状态序列，即求使得 $P(I|O)$ 最大的状态序列 $I = (i_1, i_2, \dots i_T)$

概率计算问题： 给定一个模型，计算某个特定观测序列 O 的概率 $P(O|\lambda)$

1. 直接计算法

概率公式直接算： $P(O|\lambda) = \sum_I P(O, I|\lambda) = \sum_I P(O|I, \lambda)P(I|\lambda)$

计算 $P(O|I, \lambda)$:

对固定的状态序列 $I = (i_1, i_2, \dots, i_T)$ ，观测序列 $O = (o_1, o_2, \dots, o_T)$ 的概率是：

$$P(O|I, \lambda) = b_{i_1}(o_1)b_{i_2}(o_2) \cdots b_{i_T}(o_T)$$

计算 $P(I|\lambda)$: 状态序列 $I = (i_1, i_2, \dots, i_T)$ 的概率是：

$$P(I|\lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \cdots a_{i_{T-1} i_T}$$

最终得到 $P(O|\lambda)$:

然后，对所有可能的状态序列 I 求和，得到观测序列 O 的概率 $P(O|\lambda)$ ，即

$$\begin{aligned} P(O|\lambda) &= \sum_I P(O|I, \lambda)P(I|\lambda) \\ &= \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \cdots a_{i_{T-1} i_T} b_{i_T}(o_T) \quad (\end{aligned}$$

时间复杂度 $O(TN^T)$

观测序列长度

状态个数

行不通
xíng bù tōng



概率计算问题： 计算观测序列 O 出现的概率 $P(O|\lambda)$

2. 前向算法

首先定义前向概率。

定义 10.2 (前向概率) 给定隐马尔可夫模型 λ , 定义到时刻 t 部分观测序列为 o_1, o_2, \dots, o_t 且状态为 q_i 的概率为前向概率, 记作

$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda) \quad (10.14)$$

可以递推地求得前向概率 $\alpha_t(i)$ 及观测序列概率 $P(O|\lambda)$ 。

算法 10.2 (观测序列概率的前向算法)

输入: 隐马尔可夫模型 λ , 观测序列 O ;

输出: 观测序列概率 $P(O|\lambda)$ 。

(1) 初值

$$\alpha_1(i) = \pi_i b_i(o_1), \quad i = 1, 2, \dots, N \quad (10.15)$$

(2) 递推 对 $t = 1, 2, \dots, T-1$,

$$\alpha_{t+1}(i) = \left[\sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1}), \quad i = 1, 2, \dots, N \quad (10.16)$$

(3) 终止

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i) \quad (10.17)$$

概率计算问题： 计算观测序列 O 出现的概率 $P(O|\lambda)$

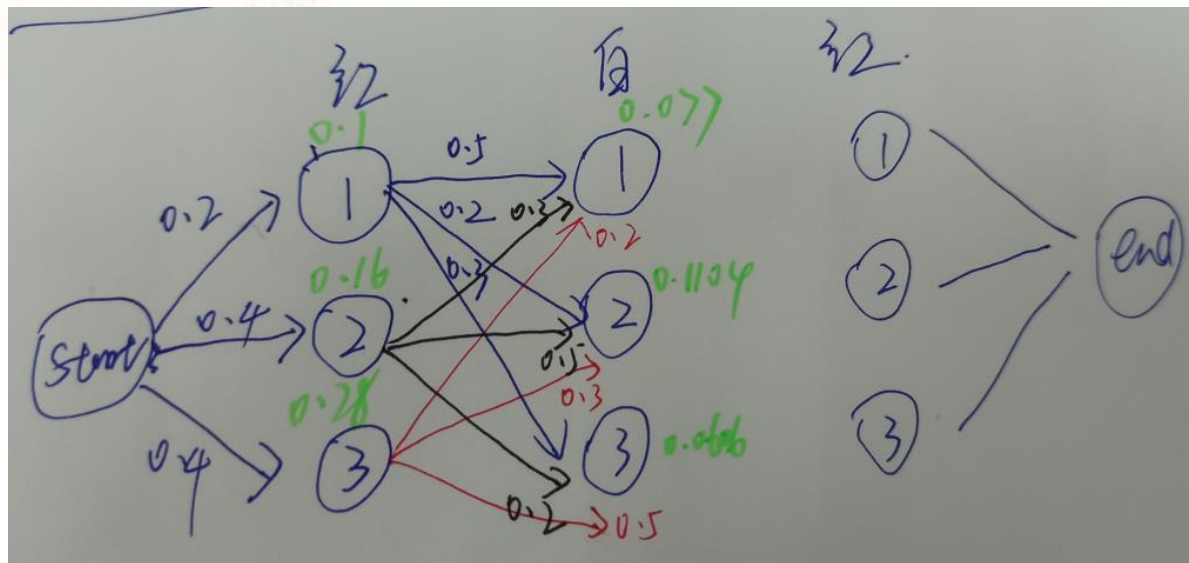
2. 前向算法——例子

例 10.2 考虑盒子和球模型 $\lambda = (A, B, \pi)$, 状态集合 $Q = \{1, 2, 3\}$, 观测集合 $V = \{\text{红}, \text{白}\}$,

$$A = \begin{matrix} & \begin{matrix} \text{盒1} & \text{盒2} & \text{盒3} \end{matrix} \\ \begin{matrix} \text{盒1} \\ \text{盒2} \\ \text{盒3} \end{matrix} & \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix} \end{matrix}, \quad B = \begin{matrix} & \begin{matrix} \text{红} & \text{白} \end{matrix} \\ \begin{matrix} \text{盒1} \\ \text{盒2} \\ \text{盒3} \end{matrix} & \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix} \end{matrix}, \quad \pi = \begin{bmatrix} 0.2 \\ 0.4 \\ 0.4 \end{bmatrix}$$

设 $T = 3$, $O = (\text{红}, \text{白}, \text{红})$, 试用前向算法计算 $P(O|\lambda)$ 。

时间复杂度 $O(TN^2)$



概率计算问题： 计算观测序列 O 出现的概率 $P(O|\lambda)$

3. 后向算法

定义 10.3 (后向概率) 给定隐马尔可夫模型 λ , 定义在时刻 t 状态为 q_i 的条件下, 从 $t+1$ 到 T 的部分观测序列为 $o_{t+1}, o_{t+2}, \dots, o_T$ 的概率为后向概率, 记作

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T | i_t = q_i, \lambda) \quad (10.18)$$

可以用递推的方法求得后向概率 $\beta_t(i)$ 及观测序列概率 $P(O|\lambda)$ 。

算法 10.3 (观测序列概率的后向算法)

输入: 隐马尔可夫模型 λ , 观测序列 O ;

输出: 观测序列概率 $P(O|\lambda)$ 。

(1)

$$\beta_T(i) = 1, \quad i = 1, 2, \dots, N \quad (10.19)$$

(2) 对 $t = T-1, T-2, \dots, 1$

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N \quad (10.20)$$

(3)

$$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i) \quad (10.21)$$



概率计算问题：计算观测序列 O 出现的概率 $P(O|\lambda)$

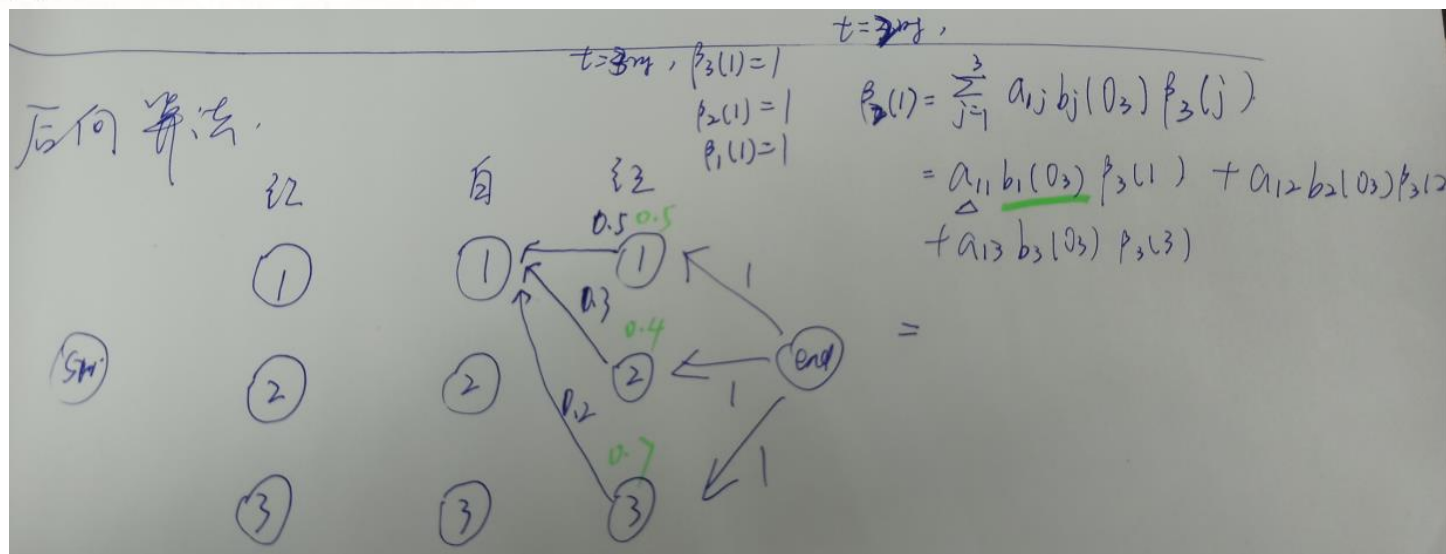
2. 后向算法——例子

例 10.2 考虑盒子和球模型 $\lambda = (A, B, \pi)$ ，状态集合 $Q = \{1, 2, 3\}$ ，观测集合 $V = \{\text{红}, \text{白}\}$ ，

$$A = \begin{matrix} & \begin{matrix} \text{盒1} & \text{盒2} & \text{盒3} \end{matrix} \\ \begin{matrix} \text{盒1} \\ \text{盒2} \\ \text{盒3} \end{matrix} & \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix} \end{matrix}, \quad B = \begin{matrix} & \begin{matrix} \text{红} & \text{白} \end{matrix} \\ \begin{matrix} \text{盒1} \\ \text{盒2} \\ \text{盒3} \end{matrix} & \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix} \end{matrix}, \quad \pi = \begin{bmatrix} 0.2 \\ 0.4 \\ 0.4 \end{bmatrix}$$

设 $T = 3$, $O = (\text{红}, \text{白}, \text{红})$ ，试用前向算法计算 $P(O|\lambda)$ 。

时间复杂度 $O(TN^2)$



HMM学习问题： 给足够量的观测数据，如何估计出HMM模型的参数 $\lambda = (A, B, \pi)$

1、有监督方式训练

假设已给训练数据包含 S 个长度相同的观测序列和对应的状态序列 $\{(O_1, I_1), (O_2, I_2), \dots, (O_S, I_S)\}$

根据条件概率，我们知道：

$$P(O_t|I_t) = \frac{P(O_t, I_t)}{P(I_t)}$$

$$P(I_t|I_{t-1}) = \frac{P(I_t, I_{t-1})}{P(I_{t-1})}$$

直接去统计：

$$P(O_t|I_t) = \frac{\#(O_t, I_t)}{\#(I_t)}$$
$$P(I_t|I_{t-1}) = \frac{\#(I_t, I_{t-1})}{\#(I_{t-1})}$$

Drawbacks:

需要大量的人工标注，代价高

HMM学习问题：给足够量的观测数据，如何估计出HMM模型的参数 $\lambda = (A, B, \pi)$

1、无监督方式训练——Baum-Welch（鲍姆-韦尔奇）

Baum-Welch算法是一种EM算法

E步，求Q函数：

$$Q(\lambda, \bar{\lambda}) = E_Z[\log(P(O, I|\lambda))|O, \bar{\lambda}]$$

$$= \sum_I \log P(O, I|\lambda) \cdot P(I|O, \bar{\lambda})$$

$$P(I|O, \bar{\lambda}) = \frac{P(I, O|\bar{\lambda})}{\boxed{P(O|\bar{\lambda})}} \quad \text{常数}$$

$$Q(\lambda, \bar{\lambda}) = \sum_I \log P(O, I|\lambda) P(O, I|\bar{\lambda})$$

其中， $\bar{\lambda}$ 是隐马尔可夫模型参数的当前估计值， λ 是要极大化的隐马尔可夫模型参数。

$$P(O, I|\lambda) = \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \cdots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

$$\begin{aligned} P(O, I|\lambda) &= \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \cdots a_{i_{T-1} i_T} b_{i_T}(o_T) \\ &= \pi_{i_1} \cdot \prod_{t=1}^{T-1} a_{i_t i_{t+1}} \cdot \prod_{t=1}^T b_{i_t}(o_t) \\ \Rightarrow Q(\lambda, \bar{\lambda}) &= \sum_I \log \left(\pi_{i_1} \cdot \prod_{t=1}^{T-1} a_{i_t i_{t+1}} \cdot \prod_{t=1}^T b_{i_t}(o_t) \right) \cdot P(O, I|\bar{\lambda}) \end{aligned}$$

于是函数 $Q(\lambda, \bar{\lambda})$ 可以写成：

$$\begin{aligned} Q(\lambda, \bar{\lambda}) &= \sum_I \log \pi_{i_1} P(O, I|\bar{\lambda}) + \sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I|\bar{\lambda}) + \\ &\quad \sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I|\bar{\lambda}) \end{aligned} \quad (10.34)$$

HMM学习问题：给足够量的观测数据，如何估计出HMM模型的参数 $\lambda = (A, B, \pi)$

1、无监督方式训练——Baum-Welch（鲍姆-韦尔奇）

M步：

$$Q(\lambda, \bar{\lambda}) = \sum_I \log \pi_{i_1} P(O, I | \bar{\lambda}) + \sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I | \bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I | \bar{\lambda}) \quad (10.34)$$

Handwritten derivation of the first term of equation 10.34:

$$\begin{aligned} \sum_I \log \pi_{i_1} P(O, I | \bar{\lambda}) &= \sum_{i_1} \sum_{i_2} \cdots \sum_{i_T} [\log \pi_{i_1} P(O, i_1, i_2, \dots, i_T | \bar{\lambda})] \\ &= \sum_{i_1} \log \pi_{i_1} P(O, i_1 | \bar{\lambda}) \\ &= \sum_{j=1}^N \log \pi_j P(O, i_1=j | \bar{\lambda}) \end{aligned}$$

注意到 π_i 满足约束条件 $\sum_{i=1}^N \pi_i = 1$ ，利用拉格朗日乘子法，写出拉格朗日函数：

$$\sum_{i=1}^N \log \pi_i P(O, i_1 = i | \bar{\lambda}) + \gamma \left(\sum_{i=1}^N \pi_i - 1 \right)$$

对其求偏导数并令结果为 0

$$\frac{\partial}{\partial \pi_i} \left[\sum_{i=1}^N \log \pi_i P(O, i_1 = i | \bar{\lambda}) + \gamma \left(\sum_{i=1}^N \pi_i - 1 \right) \right] = 0 \quad (10.35)$$

得

$$P(O, i_1 = i | \bar{\lambda}) + \gamma \pi_i = 0$$

对 i 求和得到 γ

$$\gamma = -P(O | \bar{\lambda})$$

代入式 (10.35) 即得

$$\pi_i = \frac{P(O, i_1 = i | \bar{\lambda})}{P(O | \bar{\lambda})} \quad (10.36)$$

$$\sum_I \log \pi_{i_1} P(O, I | \bar{\lambda}) = \sum_{i=1}^N \log \pi_i P(O, i_1 = i | \bar{\lambda})$$

HMM学习问题：给足够量的观测数据，如何估计出HMM模型的参数 $\lambda = (A, B, \pi)$

1、无监督方式训练——Baum-Welch（鲍姆-韦尔奇）


M步：

$$Q(\lambda, \bar{\lambda}) = \sum_I \log \pi_{i_1} P(O, I | \bar{\lambda}) + \sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I | \bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I | \bar{\lambda}) \quad (10.34)$$

$$\sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I | \bar{\lambda}) = \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \log a_{ij} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})$$

类似第1项，应用具有约束条件 $\sum_{j=1}^N a_{ij} = 1$ 的拉格朗日乘子法可以求出

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})}{\sum_{t=1}^{T-1} P(O, i_t = i | \bar{\lambda})} \quad (10.37)$$



HMM学习问题：给足够量的观测数据，如何估计出HMM模型的参数 $\lambda = (A, B, \pi)$

1、无监督方式训练——Baum-Welch（鲍姆-韦尔奇）

M步：

$$Q(\lambda, \bar{\lambda}) = \sum_I \log \pi_{i_1} P(O, I | \bar{\lambda}) + \sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I | \bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I | \bar{\lambda}) \quad (10.34)$$

$$\sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I | \bar{\lambda}) = \sum_{j=1}^N \sum_{t=1}^T \log b_j(o_t) P(O, i_t = j | \bar{\lambda})$$

同样用拉格朗日乘子法，约束条件是 $\sum_{k=1}^M b_j(k) = 1$ 。注意，只有在 $o_t = v_k$ 时 $b_j(o_t)$ 对 $b_j(k)$ 的偏导数才不为0，以 $I(o_t = v_k)$ 表示。求得

$$b_j(k) = \frac{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda}) I(o_t = v_k)}{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda})} \quad (10.38)$$

HMM学习问题： 给足够量的观测数据，如何估计出HMM模型的参数 $\lambda = (A, B, \pi)$

1、无监督方式训练——Baum-Welch （鲍姆-韦尔奇）

参数估计公式

令：

$$\gamma_t(i) = P(i_t = q_i | O, \lambda) = \frac{P(i_t = q_i, O | \lambda)}{P(O | \lambda)}$$

$$\xi_t(i, j) = P(i_t = q_i, i_{t+1} = q_j | O, \lambda)$$

$$b_j(k) = \frac{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda}) I(o_t = v_k)}{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda})}$$

$$b_j(k) = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}$$

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})}{\sum_{t=1}^{T-1} P(O, i_t = i | \bar{\lambda})}$$

$$a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$\pi_i = \frac{P(O, i_1 = i | \bar{\lambda})}{P(O | \bar{\lambda})}$$

$$\pi_i = \gamma_1(i)$$

HMM学习问题：给足够量的观测数据，如何估计出HMM模型的参数 $\lambda = (A, B, \pi)$

1、无监督方式训练——Baum-Welch（鲍姆-韦尔奇）

Baum-Welch算法流程

算法 10.4 (Baum-Welch 算法)

输入：观测数据 $O = (o_1, o_2, \dots, o_T)$ ；

输出：隐马尔可夫模型参数。

(1) 初始化。对 $n = 0$ ，选取 $a_{ij}^{(0)}$, $b_j(k)^{(0)}$, $\pi_i^{(0)}$ ，得到模型 $\lambda^{(0)} = (A^{(0)}, B^{(0)}, \pi^{(0)})$ 。

(2) 递推。对 $n = 1, 2, \dots$,

$$a_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$b_j(k)^{(n+1)} = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}$$

$$\pi_i^{(n+1)} = \gamma_1(i)$$

右端各值按观测 $O = (o_1, o_2, \dots, o_T)$ 和模型 $\lambda^{(n)} = (A^{(n)}, B^{(n)}, \pi^{(n)})$ 计算。式中 $\gamma_t(i)$, $\xi_t(i, j)$ 由式 (10.24) 和式 (10.26) 给出。

(3) 终止。得到模型参数 $\lambda^{(n+1)} = (A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)})$ 。 ■

HMM预测问题（解码）

给定训练好的HMM模型和某个特定的输出序列，

如何找到最有可能产生这个输出的隐状态序列，即求使得 $P(I|O)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$ ？



- 暴力枚举，复杂度太高，不可行。
- 贪心算法，在每个时刻 t 转移到概率最大的下一个状态，不能保证全局最优。
- 动态规划——Viterbi（维特比）算法

HMM预测问题（解码）

给定训练好的HMM模型和某个特定的输出序列，

如何找到最有可能产生这个输出的隐状态序列，即求使得 $P(I|O)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$?

维特比算法




1935年3月9日

Qualcomm

维特比算法的基础可以概括成下面三点：

1. 如果概率最大的路径 P （或者说最短路径）经过某个点，比如图中的 x_{22} ，那么这条路径上从起始点 S 到 x_{22} 的这一段子路径 Q ，一定是 S 到 x_{22} 之间的最短路径。否则，用 S 到 x_{22} 的最短路径 R 替代 Q ，便构成了一条比 P 更短的路径，这显然是矛盾的。
2. 从 S 到 E 的路径必定经过第 i 时刻的某个状态（这显然是大白话，但是很关键），假定第 i 时刻有 k 个状态，那么如果记录了从 S 到第 i 个状态的所有 k 个节点的最短路径，最终的最短路径必经过其中的一条。这样，在任何时刻，只要考虑非常有限条最短路径即可。
3. 结合上述两点，假定当我们从状态 i 进入状态 $i+1$ 时，从 S 到状态 i 上各个节点的最短路径已经找到，并且记录在这些节点上，那么在计算从起点 S 到第 $i+1$ 状态的某个节点 x_{i+1} 的最短路径时，只要考虑从 S 到前一个状态 i 所有的 k 个节点的最短路径，以及从这 k 个节点到 x_{i+1} ， j 的距离即可。



HMM预测问题（解码）

给定训练好的HMM模型和某个特定的输出序列，

如何找到最有可能产生这个输出的隐状态序列，即求使得 $P(I|O)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$?

算法 10.5（维特比算法）

输入：模型 $\lambda = (A, B, \pi)$ 和观测 $O = (o_1, o_2, \dots, o_T)$ ；

输出：最优路径 $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。

(1) 初始化

$$\delta_1(i) = \pi_i b_i(o_1), \quad i = 1, 2, \dots, N$$

$$\psi_1(i) = 0, \quad i = 1, 2, \dots, N$$

(2) 递推。对 $t = 2, 3, \dots, T$

$$\delta_t(i) = \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] b_i(o_t), \quad i = 1, 2, \dots, N$$

$$\psi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, N$$

(3) 终止

$$P^* = \max_{1 \leq i \leq N} \delta_T(i)$$

$$i_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$$

(4) 最优路径回溯。对 $t = T-1, T-2, \dots, 1$

$$i_t^* = \psi_{t+1}(i_{t+1}^*)$$

求得最优路径 $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。

HMM预测问题（解码）

给定训练好的HMM模型和某个特定的输出序列，

如何找到最有可能产生这个输出的隐状态序列，即求使得 $P(I|O)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$?

维特比算法——例子

例 10.3 例 10.2 的模型 $\lambda = (A, B, \pi)$,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = \begin{bmatrix} 0.2 \\ 0.4 \\ 0.4 \end{bmatrix}$$

已知观测序列 $O = (\text{红}, \text{白}, \text{红})$ ，试求最优状态序列，即最优路径 $I^* = (i_1^*, i_2^*, i_3^*)$ 。

